TP 4 — Web Scraping and ETL Automation

Objectif du TP : Développer un script Python permettant d'extraire automatiquement des informations depuis un site web, de nettoyer les données collectées et de les enregistrer dans un fichier exploitable.

Outils utilisés : Requests, BeautifulSoup, Pandas, Openpyxl

Sujet et travail demandé : Collecte automatisée des informations sur des livres.

Le site Books to Scrape est un site de démonstration destiné à l'apprentissage du Web Scraping.

Partie 1 — Extraction des données

1. Accéder au site avec Requests.
2. Analyser le contenu HTML avec BeautifulSoup.
   - Extraire les informations suivantes : Titre du livre, Prix, Disponibilité, Note du livre.
3. Organiser les informations dans une liste de données.

Partie 2 — Nettoyage et transformation

À l'aide de Pandas :

1. Convertir les données extraites en tableau.
2. Supprimer les doublons.
3. Supprimer les lignes dont le titre ou le prix est manquant.
4. Convertir les prix en valeurs numériques.
5. Organiser les colonnes et vérifier la cohérence des données.

Partie 3 — Exportation des résultats

1. Enregistrer les données nettoyées dans un fichier `livres.csv`.
2. Enregistrer les mêmes données dans un fichier `livres.xlsx`.
3. Vérifier que les deux fichiers contiennent les mêmes informations.

Partie 4 — Automatisation du processus

1. Regrouper les étapes d'extraction, de transformation et de chargement dans un seul script.
2. Ajouter une gestion simple des erreurs en cas d'échec de connexion.
3. Afficher le nombre de livres extraits et le nombre de livres conservés après nettoyage.
4. Relancer le script pour vérifier que le processus fonctionne sans intervention manuelle à chaque étape.