TP 5 : LLM
Découverte pratique d'un LLM avec génération et analyse d'attention

Objectifs

- Comprendre comment un LLM **tokenise et génère du texte**.
- Visualiser les **embeddings et la similarité entre tokens**.
- Observer le **mécanisme d'attention** de manière simple.

Etapes de réalisation

1. **Introduction et préparation**
   - Présenter brièvement le LLM choisi (ex : GPT-2 / GPT-Neo).
   - Installer les librairies Python : `transformers`, `torch`, `sentencepiece`, `pip install transformers torch`
2. **Tokenisation et embeddings**
   - Charger un modèle pré-entraîné :

- `from transformers import AutoTokenizer, AutoModel`
- `tokenizer = AutoTokenizer.from_pretrained("gpt2")`
- `model = AutoModel.from_pretrained("gpt2")`

   - Tokeniser une phrase et afficher les IDs des tokens.
   - Extraire les embeddings pour chaque token et visualiser une **similarité simple** (cosine similarity).
3. **Génération de texte simple**
   - Demander au modèle de compléter une phrase :
   - Observer comment le modèle choisit les tokens suivants.
4. **Visualisation simplifiée de l'attention**
   - Extraire les poids d'attention pour une phrase courte
   - Afficher une **heatmap** simple pour voir quels tokens "regardent" quels autres tokens.
5. **Discussion et analyse**
   - Comparer les tokens les plus "attendus" dans différentes phrases.
   - Relier l'observation à la théorie : tokenisation, embeddings, self-attention, génération auto-régressive.

Résultat attendu

- Compréhension pratique du **pipeline LLM** :
  - Texte → tokens → embeddings → attention → génération.
- Visualisation de la **similarité entre tokens** et des **poids d'attention**.
- Expérience concrète des différences entre tokens importants et moins importants.